

Sekcja Spark UI

Co tam jest?

Jobs	Lista wszystkich uruchomionych zadań Spark (jobs), np. agregacje, joiny, zapisy, shuffle. Informacje o czasie wykonania, statusie (Success, Failed), rozmiarze przetworzonych danych, etapach (Stages). Kliknij w DAG visualization, aby zobaczyć przepływ danych.
Stages	Rozbicie job na etapy (stages) — każdy etap to operacje między shuffle'ami. Można sprawdzić czas trwania, rozmiar danych, ilość tasków, statystyki wejścia/wyjścia, tabele Task z informacjami per-partition.
Storage	Informacje o DataFrame / RDD, które są przechowywane w pamięci (persist / cache). Widać ich rozmiar, liczbę partycji, rozmiar na węzeł.
Executors	Statystyki per-executor (maszyna Spark): ilość zadań (Tasks), ilość danych (Shuffle Read/Write), ilość pamięci, czas pracy.
SQL / DataFrame	Szczegółowe informacje o zapytaniach SQL/DataFrame API: plan wykonania (Query Plan), czas trwania, operacje fizyczne (Physical Plan).
Dystrybucja danych	Informacje o dystrybucji danych znajdziesz w Stages > Tasks (rozmiary partycji, ilość przetworzonych rekordów). W SQL UI w Query Plan – Exchange pokazuje operacje typu shuffle/repartition.